


OSPF と MPLS

Segment Routing (SR-MPLS) まで

— 研究で使用している技術を 1 から理解する —

FRR OSPF-SR + DiffServ-TE ラボ 技術解説

第 1 章	IP ルーティング基礎	— なぜ動的ルーティングが必要か
第 2 章	OSPF の仕組み	— Hello / LSA / SPF / BFD
第 3 章	MPLS の仕組み	— ラベル転送 / PUSH • SWAP • POP
第 4 章	Segment Routing (SR)	— SRGB / Node SID / 単一ラベル転送
第 5 章	本研究ラボでの動作	— 転送フロー / 障害検出 / 迂回



1.1 パケットとは？

インターネット上のデータはすべて「パケット」という小さな単位に分割されて送受信されます。各パケットには「宛先IPアドレス」が書かれた封筒のようなヘッダが付いており、ルータはこのヘッダを読んで次の転送先を決定します。

▲ IPパケットの構造（宛先IPアドレスを見てルーティングが行われる）				
宛先IP 192.168.0.5	送信元IP 10.10.1.1	TTL 64	Protocol UDP	データ (payload)

1.2 ルーティングテーブルとは？

ルータは「ルーティングテーブル」という表を持っており、「宛先Xへ行くには次ホップYに転送する」という情報が書かれています。人間で言えば「道路地図」に相当します。

宛先ネットワーク	ネクストホップ	インタフェース	メトリック
10.20.0.0/16	10.0.1.2	leri-cr1	20
192.168.0.5/32	10.0.1.2	leri-cr1	20
0.0.0.0/0	(デフォルト)	—	—

1.3 静的ルーティング vs 動的ルーティング

■ 静的ルーティング

- ・管理者が手動でテーブルを設定
- ・シンプルだが柔軟性がない
- ・リンク障害時に自動復旧しない
- ・ノード数が増えると管理不可能

■ 動的ルーティング (OSPF など)

- ・ルータが自動でテーブルを構築
- ・障害発生時に自動で迂回経路を計算
- ・大規模ネットワークに対応
- ・本研究で採用 ← ここが OSPF

【!】 本研究のポイント: OSPF（動的ルーティング）を使うことで、CR1 に障害が発生した際に CR2 / CR3 への自動迂回が実現する。これが「failure_reroute シナリオ」の核心技術。

2.1 OSPF とは？

OSPF (Open Shortest Path First) はルータ間でネットワークの「地図情報」を交換し合い、各ルータが独立して最短経路を計算するプロトコルです。
「リンクステート型」と呼ばれ、リンクの状態（接続関係・コスト）を全ルータで共有します。

2.2 Hello パケットと隣接関係 (Adjacency)

OSPF ルータは定期的に「Hello パケット」をリンクに送出します。
同じリンクに接続された別のルータが Hello を受信すると、お互いを「ネイバー (Neighbor)」として認識し、その後データベースの同期を経て「Full 状態」（隣接完成）に遷移します。



▲ OSPF 状態遷移（Full 状態になって初めて経路情報が有効になる）

2.3 Hello / Dead インターバル

Hello パケットの送出間隔と、何秒間 Hello が届かなければリンク障害と判断するかの設定値です。

hello-interval	1 秒	Hello パケット送出間隔（本研究の設定値、デフォルトは 10 秒）
dead-interval	3 秒	この秒数 Hello が届かなければ隣接消滅と判断
BFD (追加設定)	150 ms	50ms 間隔 × 3 回 = 150ms で障害検出（OSPFより高速）

2.4 ネットワーク種別: Point-to-Point (P2P)

OSPF にはリンクの種別（broadcast / P2P など）があり、本研究では全リンクを「ip ospf network point-to-point」に設定しています。これにより:

- ・ DR (Designated Router) 選出が不要 → 収束が高速
- ・ 2台のルータ間で直接隣接関係を確立 → シンプルな制御


【!】 本研究での OSPF 隣接関係:

```

LER_Ingress — CR1 (leri-cr1 / cr1-leri, 10.0.1.0/30)
LER_Ingress — CR2 (leri-cr2 / cr2-leri, 10.0.3.0/30)
LER_Ingress — CR3 (leri-cr3 / cr3-leri, 10.0.5.0/30)
CR1 — LER_Egress (cr1-lere / lere-cr1, 10.0.2.0/30)
... 合計 6 本の OSPF 隣接 (全て Full 状態) で経路情報を共有
  
```

2.5 LSA (Link State Advertisement) とは？

隣接完成 (Full 状態) 後、各ルータは自分のリンク接続情報を「LSA」というパケットにまとめてフラッディング (全隣接ルータへ転送) します。
これにより全ルータが同じ「ネットワーク地図」 (LSDB) を持つことができます。



▲ 各ルータが LSA をフラッディングし、全ルータが同じ LSDB を持つ

2.6 SPF 計算 (Dijkstra 法)

全ルータが同じ LSDB (ネットワーク地図) を持ったら、各ルータは独立して Dijkstra アルゴリズムで「自分から全宛先への最短経路」を計算します。
この計算結果がルーティングテーブルに書き込まれます。

【例】 LER_Ingress → LER_Egress (192.168.0.5) の最短経路:

経路① LER_Ingress → CR1 → LER_Egress コスト 20

経路② LER_Ingress → CR2 → LER_Egress コスト 20

経路③ LER_Ingress → CR3 → LER_Egress コスト 20

→ 3 経路が等コスト (ECMP: Equal Cost Multi-Path) → ロードバランシング

2.7 Opaque LSA と OSPF-SR への拡張

通常の LSA はリンク接続情報のみを配布しますが、「Opaque LSA」 (Type 9/10) という拡張 LSA を使うと、任意の情報を LSDB に載せてフラッディングできます。
OSPF-SR (Segment Routing) では Opaque LSA を使って「ラベル番号 (SID)」を配布します。
本研究でも show ip ospf database で Opaque-Type 7/8 の LSA が確認できています。


【!】 まとめ: OSPF = (1) Hello で隣接確立 → (2) LSA をフラッディング →
(3) LSDB を全ルータで共有 → (4) SPF で最短経路計算 → (5) ルーティングテーブル完成

3.1 MPLS とは？ — IP ルーティングの限界と解決策

通常の IP 転送では、ルータはパケットが届くたびに宛先 IP をルーティングテーブルで検索 (Longest Prefix Match) します。大規模ネットワークではこれが遅延・CPU負荷に。

MPLS (Multi-Protocol Label Switching) は IP ヘッダの前に短い「ラベル (20bit 整数)」を付けて転送を行います。ルータはラベルだけを見て転送するので非常に高速です。また、同じ宛先 IP でもラベルを変えることで異なる経路に誘導できます (Traffic Engineering)。


3.2 MPLS ラベルの構造



▲ MPLS ラベル (32 bit=4 バイト) の構造

- **ラベル値 (20 bit):** 転送先を決める整数値。本研究では 16001~16005 を使用
- **TC (3 bit):** Traffic Class: DiffServ に相当、本研究では DSCP と連動
- **S (1 bit):** Stack Bottom: ラベルスタックの最後の 1 枚なら 1 (本研究では単一ラベル)
- **TTL (8 bit):** Time To Live: ループ防止カウンタ (IP の TTL と同様)

3.3 ノードの役割: LER と LSR



LER (Label Edge Router)
ラベルを付けたり外したりするエッジルータ。
本研究: LER_Ingress (ラベル付与)、LER_Egress (ラベル除去)

LSR (Label Switching Router)
ラベルを見て転送するコアルータ (IP を見ない)。
本研究: CR1 / CR2 / CR3 がこの役割


【!】 MPLS のメリット (本研究での意義) :

- 同じ 10.20.0.0/16 宛パケットでも、DSCP クラス (AF41/42/43) ごとに異なるラベルを使って CR1/CR2/CR3 の「異なるキュー」に誘導できる。これが DiffServ-TE (クラス別トラフィックエンジニアリング) の仕組み。

3.4 3つの転送操作



3.5 本研究での MPLS 転送フロー（全体像）



3.6 本研究の MPLS テーブル（show mpls table の読み方）

LER_Ingress で実際に確認できた MPLS テーブルを解説します:

InLabel	Type	Nexthop	OutLabel	意味
16001	SR(OSPF)	lo	—	自分自身の Node SID → lo (loopback)
16002	SR(OSPF)	10.0.1.2	16002	CR1 の SID → leri-cr1 経由で転送
16003	SR(OSPF)	10.0.3.2	16003	CR2 の SID → leri-cr2 経由で転送
16005	SR(OSPF)	10.0.1.2	16005	LER_Egress の SID (ECMP 3 経路)
16005	SR(OSPF)	10.0.3.2	16005	↑ CR2 経由
16005	SR(OSPF)	10.0.5.2	16005	↑ CR3 経由

※ implicit-null: PHP (Penultimate Hop Popping)。1 つ手前のルータがラベルを除去する最適化。

4.1 Segment Routing とは？

Segment Routing (SR) は「Source Routing (送信元ルーティング)」の現代的な実装です。従来の MPLS では各 LSR が LDP/RSVP というシグナリングプロトコルでラベルを管理しましたが、SR では OSPF (または BGP/IS-IS) の拡張だけでラベルを配布するため設定がシンプルで、状態管理 (シグナリングプロトコルのセッション) が不要です。

4.2 従来 MPLS (LDP/RSVP) vs Segment Routing

	従来 MPLS (LDP/RSVP)	Segment Routing (本研究)
ラベル配布	LDP / RSVP-TE (別プロトコル)	OSPF 拡張 (Opaque LSA) のみ
状態管理	全 LSR でセッション管理が必要	不要 (ステートレス)
設定複雑度	複雑 (多数のコンフィグ)	シンプル (OSPF 設定の延長)
TI-LFA	困難	標準対応 (高速迂回)
本研究採用	—	✓ 採用

4.3 Segment の概念

SR では転送経路を「Segment (区間)」の列として表現します。各 Segment には SID (Segment ID) と呼ばれる識別子が付いており、SR-MPLS では SID が MPLS ラベル値になります。

Node SID (Prefix SID)

ルータのループバック (lo) に対応する SID。
そのルータに到達するための MPLS ラベルを表す。
本研究: LER_Egress の Node SID = 16005

Adjacency SID (Adj-SID)


特定のリンク (隣接) を指定する SID。
15000 番台 (本研究のテーブルに 15000-15005 が見える)。
ローカルに割り当てられ、OSPF フラッドイングで配布。

【!】 本研究での SID 設計: SRGB (共通ラベル空間) = 16000 ~ 23999
LER_Ingress=16001 / CR1=16002 / CR2=16003 / CR3=16004 / LER_Egress=16005

4.4 SRGB (Segment Routing Global Block)

SRGB は全ルータが共通で使うラベルの「予約範囲」です。
この範囲内のラベルは「グローバルな意味を持つ SID」として扱われ、
どのルータから見ても同じ宛先を指します。

- 本研究の設定: segment-routing global-block 16000 23999
 - Node SID = SRGB_BASE(16000) + index
 - 例: LER_Egress (index=5) → 16000 + 5 = 16005
- ラベル空間



4.5 SR-MPLS 転送フロー（単一ラベルでエンドツーエンド）

本研究での最大の特徴: 「ラベル 16005 を 1 枚付けるだけで Tx → Rx まで届く」。
各 LSR (CR1/2/3) は宛先 IP を見ずにラベルだけで転送するため、
障害時のルート変更もラベルのネクストホップを変えるだけで完了します。

Tx1 が IP パケットを送信

- ① src=10.10.1.1, dst=10.20.1.1
DSCP=AF41 (DSCP 値 34)

LER_Ingress が PUSH

- ② ip rule: DSCP AF41 → table 41
table 41: 10.20.0.0/16 via 10.0.1.2 encap mpls 16005
→ [label=16005 | IP] を leri-cr1 から出力

CR1 が SWAP (label 16005 → 16005)


- ③ show mpls table: 16005 → nexthop 10.0.2.1 outlab 16005
ラベルは同じだがネクストホップが LER_Egress 方向に変わる

LER_Egress が POP

- ④ 自分の Node SID (16005) が着信 → ラベルを除去
普通の IP パケットとして Rx1 に転送

5.1 本研究のトポロジーと役割

本研究は OSPF-SR によるトラフィックエンジニアリングと DiffServ QoS を組み合わせた「クラス別 SLA 保証」を評価するラボ実験です。3 つのトラフィッククラスを 1 本のリンク上で WRR により帯域分配します。



5.2 DiffServ クラス分類 (DSCP → fwmark → ポリシールーティング)

クラス	DSCP 値	fwmark	policy table	WRR 帯域	用途
AF41	34	41	table 41	57 Mbps (4)	高優先 (最優先保証)
AF42	36	42	table 42	28 Mbps (2)	中優先
AF43	38	43	table 43	14 Mbps (1)	低優先 (ベストエフォート)

【!】 処理の流れ: Tx が DSCP を付けた UDP → LER_Ingress の iptables が DSCP を読んで fwmark 設定 → ip rule が fwmark に応じた policy table を選択 → table41/42/43 の encap mpls ルートで転送

5.3 BFD (Bidirectional Forwarding Detection)

OSPF の障害検出は dead-interval（本研究では 3 秒）が基本ですが、BFD を併用することでこれを大幅に短縮できます。

BFD は専用の軽量 Hello パケットを高頻度で送受信し、応答が途絶えたら即座に OSPF に通知してリンクを down 扱いにします。

BFD 検出タイムライン (receive-interval=50ms, detect-multiplier=3)



5.4 障害発生から迂回完了までの流れ (failure_reroute シナリオ)

t = 0s	正常運用中。全クラス leri-cr1 (CR1) 経由。label 16005 で転送。
t = 20s	ip link set leri-cr1 down を実行 → CR1 リンクが物理的に down。
~20.15s	BFD が 150ms で検出 → OSPF に通知。FRR が隣接を即座に削除。
~20.2s	frr_te_monitor が operstate (leri-cr1 = down) を検知。
~20.2~1s	OSPF 収束待ち (wait_ospf_converge): 192.168.0.2 の隣接消滅を確認。
~21s	update_tables() 実行: table41/42/43 の nexthop を leri-cr2 (CR2) に変更。
~21s~	全クラスが CR2 経由で転送再開。実測収束時間: AF41/AF42/AF43 いずれも約 1 秒。
t = 40s	leri-cr1 up → OSPF Full 確立後に CR1 へ自動復元。

5.5 TI-LFA (Topology Independent LFA)

本研究の FRR 設定には fast-reroute ti-lfa が有効化されています。TI-LFA は障害発生時に「バックアップパス」を事前計算しておき、BFD 検出後ほぼ即座（50ms 以内）にパケットを迂回させる技術です。frr_te_monitor による動的ルート切替（~1 秒）より高速ですが、本研究では frr_te_monitor による収束時間を主に評価しています。

【!】 本研究の実測収束時間 (failure_reroute, throughput.csv より):
 AF41 (高優先 / WRR 57Mbps): 収束 1.0 秒
 AF42 (中優先 / WRR 28Mbps): 収束 1.0 秒
 AF43 (低優先 / WRR 14Mbps): 収束 1.0 秒
 → OSPF dead-interval=3s より大幅に速い (BFD 150ms 検出 + OSPF 即時収束の効果)

用語集（アルファベット順）

Adj-SID	Adjacency SID。特定リンクを指定する SR ラベル (本研究: 15000 台)
BFD	Bidirectional Forwarding Detection。50ms 周期の高速障害検出プロトコル
DiffServ	Differentiated Services。DSCP 値でトラフィッククラスを区別する QoS
DSCP	Differentiated Services Code Point。IP ヘッダ 6bit の優先度フィールド
ECMP	Equal Cost Multi-Path。同コストの複数経路をロードバランシング
FRR	FRRouting。本研究で使用するオープンソースルーティングソフトウェア
HTB	Hierarchical Token Bucket。Linux のクラスベース帯域制御 qdisc
LDP	Label Distribution Protocol。従来 MPLS のラベル配布プロトコル
LER	Label Edge Router。MPLS ドメインの境界でラベルを付与/除去
LFIB	Label Forwarding Information Base。MPLS 転送テーブル
LSA	Link State Advertisement。OSPF がフラッディングするリンク情報
LSDB	Link State Database。全ルータが共有する OSPF のネットワーク地図
LSR	Label Switching Router。ラベルのみで転送するコアルータ
MPLS	Multi-Protocol Label Switching。ラベルによる高速パケット転送
netem	Network Emulator。Linux でパケット遅延/損失を付与する qdisc
Node SID	ルータの Loopback に対応する SR SID。本研究: 16001~16005
OSPF	Open Shortest Path First。リンクステート型動的ルーティングプロトコル
OWD	One-Way Delay。送信側→受信側の片道遅延時間
PHP	Penultimate Hop Popping。最終ホップ 1 つ前でラベルを除去する最適化
SRGB	Segment Routing Global Block。SR の共通ラベル予約範囲 (本研究: 16000-23999)
SR-MPLS	Segment Routing over MPLS データプレーン
SPF	Shortest Path First (Dijkstra 法)。OSPF が最短経路を計算するアルゴリズム
TI-LFA	Topology Independent LFA。SR を利用した高速バックアップパス事前計算
WRR	Weighted Round Robin。重み付き帯域配分 (本研究: AF41:AF42:AF43 = 4:2:1)

本研究の主要設定値一覧

• OSPF hello-interval	1 秒 (デフォルト 10s → 10 倍高速)
• OSPF dead-interval	3 秒 (デフォルト 40s → 13 倍高速)
• BFD transmit/receive	50 ms, detect-multiplier=3 → 150ms 検出
• SRGB	16000 ~ 23999
• CR1~3 リンク帯域	各 100 Mbps (HTB で制限)
• WRR 比率	AF41:AF42:AF43 = 4:2:1 → 57M : 28M : 14M Mbps
• netem 追加遅延	AF42: +10ms / AF43: +40ms
• TX レート	Tx1/2/3 各 500 Mbps (UDP, iperf3)
• 計測時間	60 秒 / シナリオ (障害: t=20s down, t=40s up)
• 実測収束時間	failure_reroute: 全クラス ≈ 1.0 秒